

CONSOLIDACIÓN DE CUSTOMER LOCATIONS

Proyecto Unilever - Compra Beauty

Resumen Ejecutivo del Proceso de Identificación y Agrupación

Fecha de Análisis:	05 de Febrero, 2026
Registros Analizados:	31,664 customer locations
Grupos Identificados:	5,173
Locations Agrupadas:	14,066 (44.4%)

TABLA DE CONTENIDOS

1. Contexto y Objetivo del Proyecto
2. Análisis Inicial de Datos
3. Metodología de Consolidación
4. Resultados Principales
5. Archivos Generados
6. Scripts Desarrollados
7. Recomendaciones
8. Próximos Pasos
9. Conclusiones

1. CONTEXTO Y OBJETIVO DEL PROYECTO

El proyecto de consolidación de Customer Locations surge de la necesidad de identificar y unificar registros duplicados o relacionados en la base de datos de Compra Beauty. La proliferación de registros duplicados genera problemas operacionales, inconsistencias en reportes y dificultades en el análisis de datos.

Objetivos Principales:

- Identificar grupos de customer locations que representan la misma entidad comercial
- Clasificar los grupos por nivel de confianza para priorizar acciones
- Generar reportes detallados que faciliten la revisión manual
- Establecer criterios claros y reproducibles
- Reducir la duplicación de datos

2. ANÁLISIS INICIAL DE DATOS

2.1. Calidad de Datos

Categoría	Cantidad	Porcentaje
Total de Locations	31,664	100%
Locations con coordenadas válidas	18,900	59.7%
Locations sin coordenadas	12,764	40.3%
Locations con TaxID válido	31,478	99.4%
Locations sin TaxID	186	0.6%

2.2. Dominios de Email

Se identificaron 85 dominios corporativos (no genéricos) que agrupan a 470 usuarios. Los dominios genéricos como gmail.com, hotmail.com fueron excluidos del análisis.

3. METODOLOGÍA DE CONSOLIDACIÓN

El proceso de consolidación se dividió en dos fases complementarias. Esta aproximación permite capturar diferentes tipos de duplicación y asignar niveles de confianza apropiados.

3.1. FASE 1: Consolidación por Dominios Corporativos

Esta fase identifica locations que pertenecen a la misma organización basándose en el dominio de email corporativo del usuario creador.

Criterios: Mismo dominio corporativo • Códigos logísticos compartidos • Validación de TaxID

Resultados: 424 grupos • 3,446 locations • Requieren revisión manual

3.2. FASE 2: Consolidación por Geo-Proximidad + TaxID

Esta fase identifica locations que representan el mismo punto físico basándose en coordenadas geográficas y TaxID.

Criterios: Distancia < 50 metros • TaxID idéntico o similar • Coordenadas válidas

Resultados: 4,749 grupos • 10,620 locations • 99.95% confianza ALTA

4. RESULTADOS PRINCIPALES

4.1. Cobertura del Análisis

Métrica	Cantidad	Porcentaje
Locations analizadas	31,664	100%
Locations agrupadas	14,066	44.4%
Locations sin agrupar	17,598	55.6%
Grupos identificados	5,173	-

4.2. Nivel de Confianza de los Grupos

Confianza	Locations	Porcentaje	Acción
ALTA	10,615	75.5%	Consolidar automáticamente
MEDIA	939	6.7%	Revisión manual
BAJA	2,512	17.9%	Revisión crítica

4.3. Hallazgos Clave

Duplicación Geográfica (ALTA CONFIANZA): Se identificaron 10,615 locations con el mismo TaxID y ubicación geográfica idéntica o muy cercana. La mayoría tiene distancia = 0 metros. Causa probable: múltiples registros para el mismo punto de venta físico.

Grupos por Dominio Corporativo: El grupo más grande (CORP_0012) contiene 871 locations con 443 TaxIDs únicos. Se trata probablemente de un proveedor de servicios usado por múltiples negocios independientes.

5. ARCHIVOS GENERADOS

Se generaron múltiples archivos CSV y Excel:

- **consolidacion_completa.csv/xlsx:** Todos los grupos identificados
- **reporte_consolidacion_detallado.csv/xlsx:** Información enriquecida
- **reporte_grupos_alta_confianza.csv/xlsx:** Listos para consolidar (10,615 locations)
- **reporte_grupos_revision.csv/xlsx:** Requieren análisis manual (3,451 locations)
- **estadisticas_por_grupo.csv/xlsx:** Métricas agregadas
- **fase1_consolidacion_dominios_corporativos.csv/xlsx:** Resultados Fase 1
- **fase2_consolidacion_geo_proximidad.csv/xlsx:** Resultados Fase 2
- **reporte_grupos_dominios_detallado.xlsx:** Reporte Fase 1 formateado
- **reporte_grupos_geolocalizacion_detallado.xlsx:** Reporte Fase 2 formateado

6. SCRIPTS DESARROLLADOS

Se desarrollaron varios scripts Python para automatizar el proceso:

- **consolidacion_customer_locations.py:** Script principal que ejecuta ambas fases de consolidación.
- **generar_reporte_detallado.py:** Enriquece resultados con información adicional.
- **generar_reporte_dominios_detallado.py:** Genera reporte Excel formateado para Fase 1.
- **generar_reporte_geo_detallado.py:** Genera reporte Excel formateado para Fase 2.

6.1. Componentes Técnicos

- **Algoritmo de Grid Espacial:** Optimización que reduce complejidad de $O(n^2)$ a $O(n \times k)$
- **Distancia Haversine:** Cálculo preciso en coordenadas esféricas
- **Similitud Levenshtein:** Comparación de TaxIDs con posibles errores
- **Validación de Conflictos:** Sistema de alertas automáticas

7. RECOMENDACIONES DE IMPLEMENTACIÓN

7.1. Acción Inmediata: Consolidación de ALTA Confianza

Target: 10,615 locations en 4,749 grupos

Impacto: Reducción del 33.5% en registros

Proceso:

1. Revisar muestra de 50-100 grupos
2. Implementar consolidación automática
3. Seleccionar location master
4. Ejecutar consolidación
5. Monitorear resultados

7.2. Acción Secundaria: Revisión Manual

Target: 3,446 locations en 424 grupos (Fase 1)

- TaxIDs idénticos → Consolidar
- TaxIDs distintos → NO consolidar
- Mix de TaxIDs → Investigar

7.3. Acción Preventiva

- Validación en registro
- Reglas de unicidad
- Geocodificación
- Detección en tiempo real

8. PRÓXIMOS PASOS

8.1. Corto Plazo

- ✓ Revisar muestra de grupos ALTA confianza
- ✓ Ejecutar consolidación automática
- ✓ Configurar validaciones

8.2. Mediano Plazo

- Revisar grupos MEDIA confianza
- Resolver grupos BAJA confianza
- Mejorar flujo de registro

8.3. Largo Plazo

- Geocodificar locations
- Detección de duplicados en tiempo real
- Auditoría periódica
- Dashboard de monitoreo

9. CONCLUSIONES

Alta duplicación: 44.4% de locations duplicadas, gran oportunidad de mejora.

Consolidación inmediata: 10,615 registros con ALTA confianza listos para consolidar.

Metodología robusta: Proceso transparente, documentado y reproducible.

Prevención necesaria: Implementar controles en el momento de creación.

Calidad mejorable: 40.3% sin coordenadas válidas limita efectividad.

Atención especial: Grupos corporativos grandes requieren revisión cuidadosa.

Este análisis proporciona una base sólida para tomar decisiones informadas sobre la consolidación de customer locations. Los reportes facilitan tanto la implementación automática como la revisión manual de casos especiales.